

Wykorzystanie sieci neuronowych do wykrywania zmian w obrazach medycznych

(English title)

Tomasz Nanowski

Praca inżynierska

Promotor: dr Jan Chorowski

Uniwersytet Wrocławski
Wydział Matematyki i Informatyki
Instytut Informatyki

12 stycznia 2019

Tomasz Nanowski

.....

.....

(adres zameldowania)

.....

.....

(adres korespondencyjny)

PESEL:

e-mail:

Wydział Matematyki i Informatyki

stacjonarne studia I stopnia

kierunek: informatyka

nr albumu: 279076

Oświadczenie o autorskim wykonaniu pracy dyplomowej

Niniejszym oświadczam, że złożoną do oceny pracę zatytułowaną *Wykorzystanie sieci neuronowych do wykrywania zmian w obrazach medycznych* wykonałem/am samodzielnie pod kierunkiem promotora, dr. Jana Chorowskiego. Oświadczam, że powyższe dane są zgodne ze stanem faktycznym i znane mi są przepisy ustawy z dn. 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (tekst jednolity: Dz. U. z 2006 r. nr 90, poz. 637, z późniejszymi zmianami) oraz że treść pracy dyplomowej przedstawionej do obrony, zawarta na przekazanym nośniku elektronicznym, jest identyczna z jej wersją drukowaną.

Wrocław, 12 stycznia 2019

(czytelny podpis)

Streszczenie

Celem projektu jest wykorzystanie modelu VAE do wykrywania zmian patologicznych w obrazach medycznych

...

Spis treści

1. Introduction	7
2. Artificial neural networks	9
2.1. Autoencoders	9
2.2. VAE	9
2.3. Convolution VAE	10
2.4. Deep feature consistent variational auto-encoder	10
3. MNIST experiments	11
3.1. MNIST	11
3.2. VAE	11
3.3. Deep feature consistent variational auto-encoder	12
4. Medical Dataset	15
4.1. Description	15
4.2. Preprocessing	15
4.3. Patches	15
4.4. Normalizations	15
5. Experiments on medical dataset	17
5.1. VAE	17
5.2. C-VAE	17
6. Workflow	19
7. Summary	21

Rozdział 1.

Introduction

Rozdział 2.

Artificial neural networks


Sztuczne sieci neuronowe mają obecnie bardzo mocno ugruntowaną pozycję szczególnie w dziedzinie problemów związanych z analizą i przetwarzaniem obrazów. Pomimo, iż nie jest to nowy pomysł, dopiero ostatni wzrost w wydajności komputerów pozwolił na ich praktyczne zastosowanie. Z matematycznego punktu widzenia są to sparametryzowane nieliniowe funkcje o pewnej ustalonej strukturze. Składają się z prostych elementów zwanych neuronami, a one natomiast są pogrupowane w warstwy. Połączenia między warstwami definiują przepływ danych. 'Nauka' sieci neuronowych polega na optymalizacji pewnej funkcji straty, czyli wyznaczeniu takich parametrów, żeby osiągnąć minimalny koszt. Do tego celu często korzysta się z metod opartych na SGD, a przy wybranej strukturze można w efektywny sposób zastosować algorytm propagacji wstecznej. W dalszej części pracy będę używał prostszej nazwy (neural nets). Przykładowa architektura sieci neuronowych jest zaprezentowana na wykresie ???.

2.1. Autoencoders

Jest to jeden z rodzajów sieci neuronowych, służący do znajdowania wydajnej reprezentacji danych, co jest przykładem nauki bez nadzoru. W autoencoder'ach można wyróżnić dwie części: encoder i decoder. Zadaniem encodera jest wyprodukowanie reprezentacji, natomiast decoder służy do odtworzenia z niej oryginalnej postaci. Zależy nam na tym, żeby wyjście było w jakimś sensie jak najbardziej podobne do wejścia. W przypadku obrazów jako funkcja straty często stosowane jest MSE. Przykładowy schemat na wykresie 2.1.

2.2. VAE

Variational autoencoders rezszerzają założenia o wprowadzenie modelowania rozkładu prawdopodobieństwa dla reprezentacji ukrytej.



Rysunek 2.1: Architecture of autoencoder

2.3. Convolution VAE

Jest to rozszerzenie poprzedniego modelu, w którym dodatkowo stosujemy warstwy splotowe. Szczególnie w przypadku obrazów pozwala to na zwiększenie rozmiaru danych wejściowych przez zmniejszenie ilości parametrów w stosunku do warstw fully-connected oraz wykryciu na wstępie jakiś prostych cech, przez co w reprezentacji mogą znajdować się bardziej abstrakcyjne rzeczy.

2.4. Deep feature consistent variational auto-encoder

Ta wersja zakłada użycie innej funkcji kosztu. MSE z samej definicji przyczynia się do uśredniania wartości pikseli przez co wyjściowy obraz nie jest wyraźny. W tym przypadku będziemy korzystać z zewnętrznej sieci splotowej wyuczonej do klasyfikacji obrazów. Będziemy teraz myśleć, że dwa obrazy są podobne, jeśli mają podobne wartości aktywacji w tej sieci. Takie podejście powinno nam dać ostrzejsze wyjście.

Rozdział 3.

MNIST experiments

3.1. MNIST


Jest to zbiór pokategoryzowanych odręcznie napisanych cyfr. Wszystkie obrazki są czarno-białe, rozmiaru 28x28 i wycentrowane. Zbiór składa się z 60000 danych treningowych i 10000 testowych. Zbiór ten często wykorzystywany jest w celu eksperymentowania z modelem, jednak jest na tyle mało skomplikowany, że daje jedynie poglądowe informacje. Przykładowe obrazki 3.1.



Rysunek 3.1: Samples from MNIST dataset

3.2. VAE


Wyniki przy użyciu zwykłego VAE



Rysunek 3.2:

3.3. Deep feature consistent variational auto-encoder

Wyniki przy użyciu Deep feature consistent variational auto-encoder.



Rysunek 3.3:

Rozdział 4.

Medical Dataset

Dane pochodzą z Uniwersytetu ... z USA.

4.1. Description

4.2. Preprocessing

Opis preprocessingu

4.3. Patches

Wybór rozmiaru patchy i ekspeymenty z tym związane

4.4. Normalizations

Może LIME?

Rozdział 5.

Experiments on medical dataset

5.1. VAE

5.2. C-VAE

Rozdział 6.

Workflow

Rozdział 7.

Summary