

Zastosowanie autoenkoderów wariacyjnych do rozpoznawania zmian na obrazach medycznych

Tomasz Nanowski

II UW_r

15 lutego 2019

Plan prezentacji

Opis problemu

Autoenkoder wariacyjny

Eksperyment na danych syntetycznych (MNIST)


Eksperyment na danych medycznych

Wnioski

Opis problemu

Opis problemu

Lokalizowanie zmian nowotworowych na zdjęciach wykonanych metodą rezonansu magnetycznego (MRI, *ang. magnetic resonance imaging*).



Podjęcie nadzorowane

Opis

Bazowanie na danych przeanalizowanych wcześniej przez specjalistów, gdzie każdy przypadek został ręcznie obejrzany i oznaczony. Przykładowo można byłoby skorzystać z architektury *U-Net*.

Podjęcie nadzorowane

Opis

Bazowanie na danych przeanalizowanych wcześniej przez specjalistów, gdzie każdy przypadek został ręcznie obejrzany i oznaczony. Przykładowo można byłoby skorzystać z architektury *U-Net*.

Zalety

- + wykorzystanie rzeczywistej wiedzy eksperckiej

Podjęcie nadzorowane

Opis

Bazowanie na danych przeanalizowanych wcześniej przez specjalistów, gdzie każdy przypadek został ręcznie obejrzany i oznaczony. Przykładowo można byłoby skorzystać z architektury *U-Net*.

Zalety

- + wykorzystanie rzeczywistej wiedzy eksperckiej

Wady

- zbiór danych kosztowny w przygotowaniu i dalszym rozwoju
- ograniczenie do pojedynczego obszaru ciała

Podjęcie wykorzystane w pracy

Obserwacja

Występujące zmiany nowotworowe są ogólnie rzadkie oraz są pewnym odstępstwem od normy. Można potraktować to jako problem wykrywania obserwacji odstających (*ang. outlier*).

Podjęcie wykorzystane w pracy

Obserwacja

Występujące zmiany nowotworowe są ogólnie rzadkie oraz są pewnym odstępstwem od normy. Można potraktować to jako problem wykrywania obserwacji odstających (*ang. outlier*).

Pomysł

Wykorzystanie autoenkodera wariacyjnego, który uczy się modelować rozkład prawdopodobieństwa danych treningowych. Próbkę mało prawdopodobną będą oznaczane jako patologiczne.

Autoenkoder wariacyjny


Funkcja kosztu

Dolne ograniczenie prawdopodobieństwa

$$\begin{aligned} \log p(x) &\geq -l_i(\theta, \phi) = ELBO_i(\theta, \phi) = \\ \mathbb{E}_{q_\theta(z|x_i)} [\log p_\phi(x_i|z)] - \mathbb{KL}(q_\theta(z|x_i) \| p(z)) \end{aligned} \quad (1)$$

Interpretacja:

- ▶ $\mathbb{E}_{q_\theta(z|x_i)} [\log p_\phi(x_i|z)]$ można utożsamiać z błędem rekonstrukcji, gdyż odpowiada temu składnik $\log p(x|z)$. Dodatkowo jest to potęgowane przez $q(z|x)$, czyli pewność co do reprezentacji ukrytej.
- ▶ $\mathbb{KL}(q_\theta(z|x_i) \| p(z))$ można interpretować jako ilość przesłanych informacji, ponieważ jeżeli model będzie chciał odejść od rozkładu a priori $p(z)$ to zapłaci za to karę, ale będzie w stanie przekazać wiadomość.



Rysunek: Rozkład konkretnych próbek w przestrzeni ukrytej z zaznaczonym odchyleniem standardowym

Eksperyment na danych syntetycznych (MNIST)

Plan eksperymentu


Skład zestawu **uczącego**:

- ▶ cyfry **4, 7** $\sim 99\%$
- ▶ cyfra **5** $\sim 1\%$ (próbka odstająca)


Skład zestawu **testowego**:

- ▶ cyfry **4, 7** $\sim 50\%$
- ▶ cyfra **5** $\sim 50\%$ (próbka odstająca)

Badałem skuteczność separacji danych na podstawie oszacowania przez model dolnego prawdopodobieństwa *ELBO* (suma kosztu rekonstrukcji i KLD)



Rysunek: Rozkład próbek wraz z przykładami ze względu na poszczególne składniki funkcji straty



Rysunek: Krzywa ROC dla modelu wyuczonego na danych syntetycznych z zachowaniem odpowiedniej dysproporcji w danych

Eksperyment na danych medycznych

przed podaniem
kontrastu



FLAIR



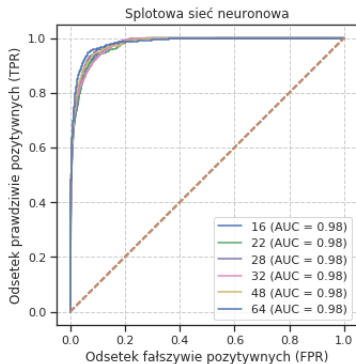
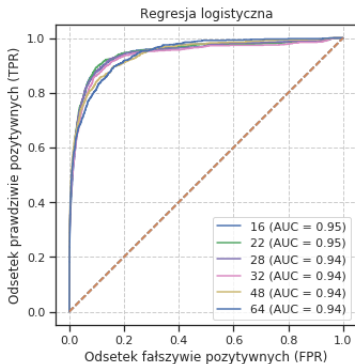
po kontraście



maska obszaru
zmian
nowotworowych



Rysunek: Przedstawienie konkretnych kanałów w próbce wraz z jego maską zmian

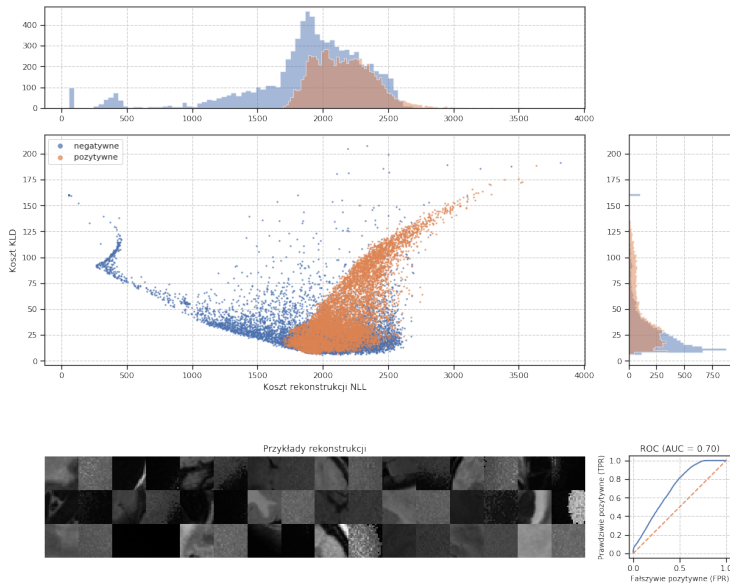


Rysunek: Porównanie dokładności ze względu na różne rozmiary wycinków dla modeli uczonych metodą nadzorowaną


Wyniki eksperymentu

Model	Epoka					
	1	2	3	20	60	80
VAE 20-d	0.494	0.693	0.655	0.612	0.597	0.590
VAE 50-d	0.552	0.686	0.697	0.616	0.606	0.592
VAE 100-d	0.580	0.685	0.701	0.614	0.595	0.594
VAE 200-d	0.661	0.675	0.668	0.620	0.608	0.597
VAE 300-d	0.704	0.671	0.657	0.620	0.600	0.593

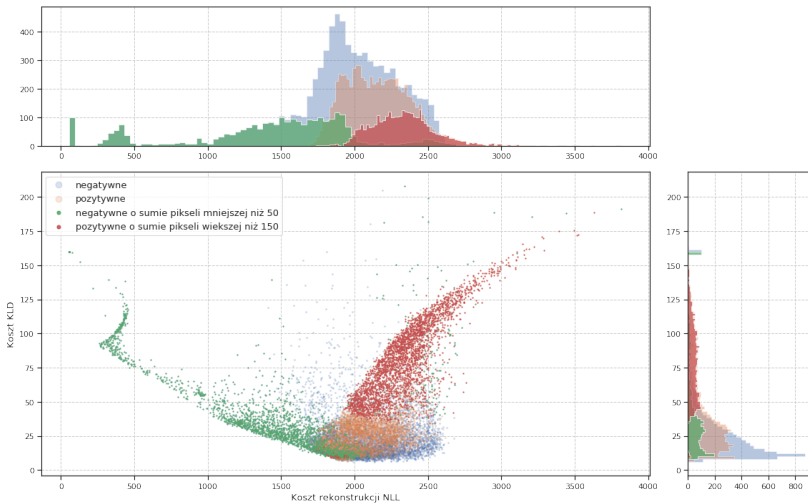
Tablica: AUC ze względu na rozmiar reprezentacji ukrytej i w różnych stadiach nauki



Rysunek: Poszczególne składniki kosztu dla modelu z najlepszą separowalnością



Rysunek: Rozkład sum pikseli dla obrazków ze zbioru testowego



Rysunek: Zaznaczenie obrazków o konkretnych sumach pikseli

Wnioski

Usprawnienia

- ▶ zastosowanie normalizacji w postaci wyrównywania histogramu (*ang. histogram equalization*), co pozwoliłoby złagodzić jasność
- ▶ usunięcie zbędnych danych z obrazu w postaci czaszki i oczu, które mogą przeszkadzać w modelowaniu
- ▶ rozszerzyć kontekst próbki, np. poprzez dodanie dodatkowych informacji o sąsiedztwie do dekodera

Dziękuję za uwagę